О чем была

Super-Convergence Very Fast Training of Neural Networks Using Large Learning Rates

О чём эта работа

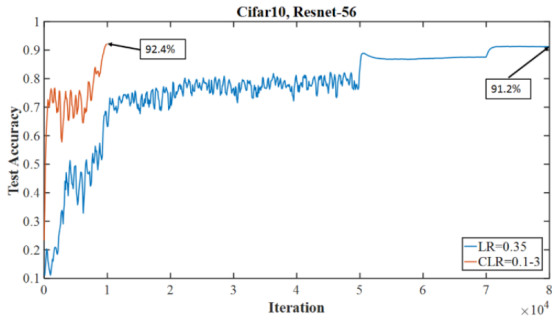
Нейросети обычно обучают с небольшим learning rate: ждут, пока обучение замедлится, затем уменьшают LR и продолжают. Авторы задают простой вопрос: **что, если гораздо больший LR позволит прийти к хорошему решению быстрее?** (причем будем регулировать LR по расписанию)

В статье сравнивают два режима обучения одной ResNet-56 на CIFAR-10.

Обычное ступенчатое уменьшение LR: **91.2% за 80 тысяч итераций**.

Один цикл с большим LR: **92.4% за 10 тысяч итераций**.

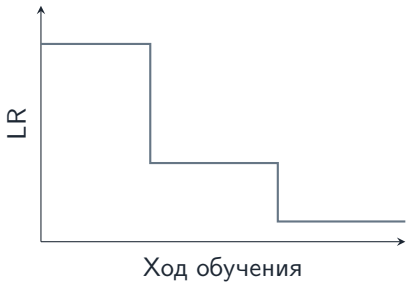
Разница не только в качестве, но и в количестве шагов — примерно **8 раз**.



Как обычно обучали сети

- SGD с LR порядка 0.1.
- Длинный участок обучения.
- После выхода на плато LR уменьшают примерно на порядок.
- Повторяют несколько раз.

Это и есть baseline метод статьи: *piecewise constant learning rate*.



Почему не поднять learning rate сразу?

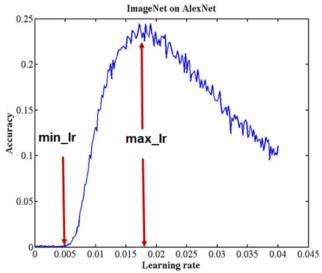
Слишком большой LR - проскакиваем минимум, малый - долго сходимся.

Но **«оптимально большой» зависит от модели и режима обучения**. Авторы обнаружили, что ResNet на CIFAR-10 может сохранять хорошее качество даже при LR, существенно превышающем привычные значения.

Отсюда идея: сначала определить допустимый диапазон LR, затем использовать его в коротком обучении.

LR range test

1. Начинаем обучение с очень маленьким LR.
2. Постепенно увеличиваем LR на протяжении пробного запуска.
3. Отслеживаем loss и accuracy.
4. Выбираем верхнюю границу по поведению модели.



1cycle

1. **Разгон:** LR растёт от небольшого до максимального.
2. **Спуск:** LR возвращается вниз.
3. **Финиш:** LR снижается ещё на несколько порядков.

Последняя фаза помогает стабилизировать решение после обучения с большим шагом.



1cycle

1. **Пробный запуск:** LR увеличивают от почти нуля, отслеживают accuracy по мере роста.
2. **Обычный LR range test:** верхнюю границу выбирают около пика accuracy; нижнюю можно взять в 3–4 раза меньше.
3. **Необычный случай:** если качество держится при гораздо больших LR, авторы пробуют высокий максимум (например, до 3 для CIFAR-10 / ResNet-56).
4. **Основное обучение:** один цикл роста и снижения LR, затем дополнительный спад на несколько порядков до завершения обучения.

Немного математики

$$\boxed{\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)}$$

- θ_t — веса сети на текущей итерации;
- $L(\theta)$ — функция потерь;
- ∇L — направление наиболее быстрого роста ошибки;
- η — длина шага (learning rate).

Мы идём **против градиента**, чтобы уменьшить loss.

Проблема: градиент задаёт направление *локально*, но не говорит, насколько далеко безопасно двигаться.

Вывод: выбор η определяется не только величиной градиента, но и формой поверхности loss.

Немного математики

$$L(\theta + \Delta) \approx L(\theta) + g^\top \Delta + \tfrac{1}{2}\Delta^\top H \Delta$$

Здесь $g = \nabla L(\theta)$, а $H = \nabla^2 L(\theta)$ — **матрица Гессе**.

Линейный член $g^\top \Delta$ отвечает за наклон, квадратичный $\Delta^\top H \Delta$ — за **изменение наклона**.

Большая кривизна: градиент резко меняется; большой шаг может перескочить минимум.

Малая кривизна: направление градиента меняется медленно; потенциально возможен больший шаг.

Вывод: хотелось бы оценить кривизну, но хранить полный H для большой сети слишком дорого.

Немного математики

Авторы используют идею *Hessian-free*: смотреть, как **меняется градиент вдоль сделанного шага**.

$$\boxed{H\Delta \;\approx\; \nabla L(\theta+\Delta) - \nabla L(\theta)}$$

При движении по одной координате отношение изменения градиента к изменению веса приблизительно задаёт кривизну:

$$\frac{\Delta g}{\Delta \theta} \;\approx\; \text{локальная кривизна}, \qquad \eta^* \;\approx\; \frac{\Delta \theta}{\Delta g}.$$

Смысл: если градиент меняется мало при заметном изменении веса, оценка допустимого LR получается большой.

это приближённая оценка из статьи, не готовый метод поиска глобального оптимума.

Немного математики

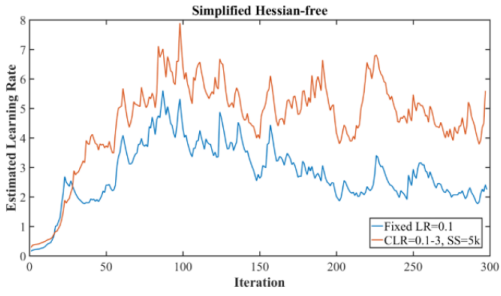
Формула даёт оценку для каждого веса. Авторы получают глобальную оценку, суммируя модули:

$$\eta^* \approx \eta \frac{\sum_j |\theta_{t+1,j} - \theta_{t,j}|}{\sum_j |2\theta_{t+1,j} - \theta_{t,j} - \theta_{t+2,j}|}$$

Оценки сильно колеблются, поэтому применяется **скользящее среднее**:

$$\boxed{r_t = \alpha \eta_t^* + (1-\alpha) r_{t-1}} \qquad \alpha = 0.1$$

Результат: сглаженная оценка LR достигает значений порядка **2–6**.

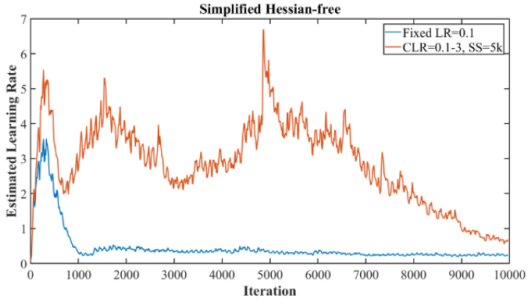


Немного математики

Постановка:
ResNet-56, CIFAR-10.
Сравниваются два режима:

- постоянный LR = 0.1;
- CLR от 0.1 до 3.

Оценка LR проводится на протяжении 10 000 итераций по весам, сохраняемым каждые 10 шагов.



Результат:
При постоянном LR оценка после начального всплеска падает примерно до 0.2.
При CLR она остаётся высокой почти всё обучение и к концу приближается к 0.5.

Вывод: авторы связывают большие оценки LR с небольшой локальной кривизной loss.

Итог математики

Что показал эксперимент:

- оценённый LR может достигать значений порядка 2–6;
- это значительно выше привычных значений около 0.1;
- большие оценки авторы связывают с небольшой локальной кривизной loss.

Практический смысл: такие LR стоит попробовать при обучении нейросетей. Диапазон авторы определяют с помощью LR range test, а затем используют расписание 1cycle.

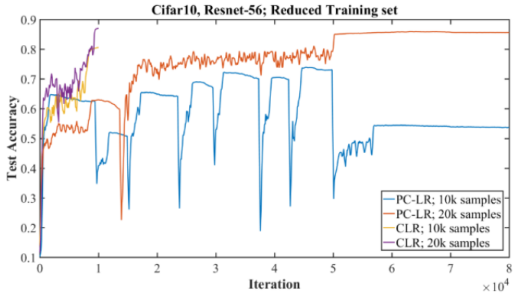
При этом математическая оценка - объяснение наблюдаемого эффекта.

Эксперимент 1. Влияние количества данных

Постановка
CIFAR-10, ResNet-56. Обучающая выборка сокращается до 40k, 30k, 20k и 10k примеров.

Сравниваются два режима:

- Standard: PC-LR = 0.35, 80k итераций.
- CLR: LR от 0.1 до 3, 10k итераций.
- Настройки BatchNorm также различаются.



Результат
При 40k примеров: 89.1% → 91.1%.
При 10k примеров: 71.4% → 80.6%.

Вывод: при уменьшении датасета преимущество CLR возрастает с 2.0 до 9.2 п.п.

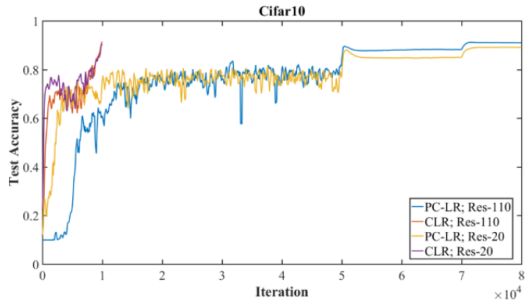
Эксперимент 2. Влияние глубины сети

Постановка
CIFAR-10, ResNet глубиной от 20 до 110 слоёв. Сравниваются стандартное расписание LR и CLR.

Результаты

Модель	Standard	CLR
ResNet-20	88.6%	90.4%
ResNet-110	91.0%	92.1%

Вывод
CLR улучшает результат для обеих архитектур. При этом для ResNet-20 прирост больше: $+1.8$ против $+1.1$ п.п.



Эксперимент 3. Другие модели и датасеты

Постановка
Авторы проверяют, сохраняется ли эффект 1cycle на других архитектурах и задачах: MNIST, CIFAR-10 и CIFAR-100.

Задача / метод	Эпохи	Accuracy
MNIST / Standard	85	99.03%
MNIST / 1cycle	12	**99.25%**
CIFAR-100 / Standard	200	61.6%
CIFAR-100 / 1cycle	100	**69.0%**
CIFAR-10 / DenseNet	400	92.7%
CIFAR-10 / 1cycle	150	**92.8%**

Результат
На MNIST LeNet достигает более высокой точности за 12 вместо 85 эпох.

На CIFAR-100 ResNet-56 получает 69.0% за 100 эпох против 61.6% за 200.

Вывод
Эффект наблюдается и на других моделях и датасетах.

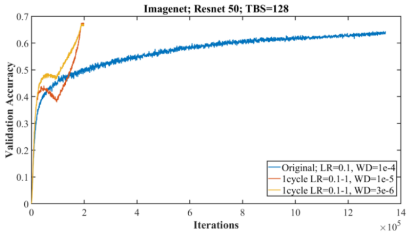
Эксперимент 4. ImageNet

Постановка
ImageNet, две архитектуры: ResNet-50 и Inception-ResNet-v2.
Standard обучается 100 эпох, 1cycle — 20 эпох.
Для использования больших LR авторы уменьшают weight decay.

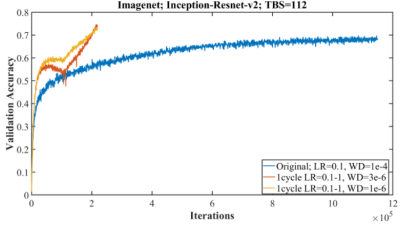
Результаты
ResNet-50:
63.7% → **67.6%**

Inception-ResNet-v2:
67.6% → **74.0%**

Вывод
Super-convergence наблюдается и на более масштабных задачах, причём за меньшее число эпох.



(a) Resnet-50



(b) Inception-resnet-v2

Заключение

В работе авторы показали, что использование **одного цикла с большим learning rate** может значительно ускорить обучение нейросетей.

Основные результаты:

- На CIFAR-10 ResNet-56 достигает **92.4% за 10k итераций** вместо 91.2% за 80k.
- Преимущество особенно заметно при ограниченном количестве обучающих данных.
- Эффект наблюдается на разных архитектурах и датасетах, включая ImageNet.

Основная идея статьи:
Большие learning rates могут действовать как дополнительная регуляризация. Поэтому для успешного применения 1cycle важно не только подобрать диапазон LR, но и согласовать его с другими гиперпараметрами обучения.

Метод не гарантирует ускорение в любой задаче: результат зависит от архитектуры и настроек обучения.